

TEKNOFEST Saglikta Yapay Zeka Yarismasi

63.000 Satirlik Genis Veri (ClinVar/OpenCRAVAT)

Uzerinde Modelleme Calismasi - Ozet Rapor

Notebook 50 - Notebook 54 (NB50-NB54) calismalarinin konsolide sonucu

Tarih: 2026-08-31

Hazirlayan: Proje ekibi (Claude Code destegiyle)

0. Bu Rapor Ne Anlatiyor?

Bu rapor, TEKNOFEST projesinde daha once kullanilan 'yarisma verisi' (anonimlestirilmis, ~2900-3700 satirlik kucuk paneller: MASTER/CFTR/KANSER/PAH) disinda, tamamen ayri bir veri kumesi uzerinde yapilan yeni bir calisma dizisini ozetler.

Bu yeni veri kumesi 'ClinVar/OpenCRAVAT' kaynakli, acik sutun isimli (REVEL, AlphaMissense, CADD, gnomAD frekansi gibi taninmis biyoenformatik skorlar iceren), 63.463 satirlik cok daha buyuk bir genetik varyant tablosudur. Kullanicinin 'final test dagilimi (yarismanin sunacagi %80 benign / %20 patojenik) diye bir sey olmayacak, elimizdeki veriyle model egitecegiz' kararindan sonra bu hat acilmistir; dolayisiyla asagida anlatilan tum surec, projenin daha once uzerinde calistigi yarisma panelleriyle KARISTIRILMAMALIDIR -- farkli veri, farkli olcek, farkli bulgular.

Bes notebook (NB50 -> NB54) sirayla su asamalari kapsar: (1) veriyi temizleyip etiketlemek, (2) sizinti/guvenilirlik denetimi yapmak, (3) hangi modelleme stratejisinin ise yaradigini sistematik olarak test etmek, (4) o stratejiyi ince ayarla optimize etmek, (5) modeli sadece BIR KEZ, hic gormedigini bir test bolumu uzerinde nihai olarak degerlendirmek.

Okuma rehberi

'F1' = modelin hem yanlis alarm vermeme (precision) hem de gercek vakalari kacirmama (recall) basarisini tek sayida ozetleyen, 0 ile 1 arasinda degisen bir skor (1 = mukemmel). 'MCC' benzer amacli ama dengesiz veri kumelerinde daha guvenilir kabul edilen bir baska skor. 'Floor-F1' ise 'hicbir sey ogrenmeden, hep ayni tahmini yap' stratejisinin verecegi taban skordur -- modelin gercekten bir sey ogrendigini gostermek icin bu tabani asmasi sarttir.

1. Veri Kumesi ve Ilk Hazirlik (NB50)

1.1 Veri buyuklugu

Ham dosya: 824 MB, 63.463 satir, 777 sutun (OpenCRAVAT semasi). Etiket (Label: 0=iyi huylu/benign, 1=hastalik yapici/pathogenic) ClinVar'in klinik anlam sutunundan turetildi; 11 satir belirsiz etiketli oldugu icin (celiskili veya eksik klinik yorum) veri disi birakildi.

Calisma yalnızca 'missense' varyantlar (bir amino asidi baska birine ceviren mutasyonlar) üzerinde yurutuldu -- bu, patojenite tahmininde en zor ve en cok arastirilan varyant tipidir:

Alt kume	Satir sayisi	Benign	Pathogenic	Prevalans (pathogenic)
Missense (ana calisma seti)	60.970	38.248	22.722	%37,3
Non-missense (ek/ayri)	2.482	-	-	-

Onemli fark: bu veri kumesinin prevalansi, yarisma panellerinden koklu sekilde farkli

Yarisma panellerinde (MASTER/KANSER/PAH) egitim verisi cogunlukla pathogenic agirlikliydi (%73-83) ve final test setinin tam tersi (%80 benign) olacagi biliniyordu -- bu, o hatta onemli bir 'ters dagilim' sorunu yaratiyordu. 63k veri kumesinde ise boyle bir varsayim YOK: %37,3 pathogenic prevalans hem egitimde hem beklenen kullanimda ayni kabul ediliyor. Floor-F1 (hep pathogenic tahmin etme stratejisinin skoru) burada 0,543 -- yarisma panellerinin floor'larindan (0,82-0,91) cok daha dusuk, yani modelin gosterebilecegi gercek marj (tavan ile taban arasindaki fark) burada cok daha genis.

1.2 Sizinti temizligi (kritik adım)

Ham veride modelin 'hile yaparak' etiketi dogrudan gormesine yol acabilecek sutunlar cikarildi: ClinVar'in kendi klinik yorum sutunlari (40 adet), varyant kimlik/serbest metin/transkript sutunlari (161 adet, kanser-alt-tipi CHASMplus ciftleri dahil). Boylece 777 sutun -> 611 sutune indi.

Ardindan sabit (tek deger alan, bilgi tasimayan) ve birebir ozdes sutun ciftleri de temizlendi (70 sabit + 3 ozdes cift) -> 611 -> 538 sutun.

Iteratif sizinti avi -- ilk liste eksik cikti (NB51'de duzeltildi)

NB50'nin ilk sizinti listesi eksikti: dbNSFP'nin 'rankscore' ailesi (23 sutun), VARIETY ve VEST meta-tahminleyicileri, ve bazi literatur-referans sutunlari (orn. bir varyantin literaturde kac kez gectigini sayan sutun -- ClinVar'a giren varyantlar zaten daha cok calisilmis oldugu icin bu dolayli bir sizinti riskiydi) eksikti. NB51'de bu bulunup duzeltildi, veri yeniden uretili (nihai: 533 sutun). Bu, 'bir kere sizinti taradik, bitti' degil, surekli dogrulan bir surec oldugunu gosteriyor.

1.3 Ilk kesif bulgulari

- Eksiklik (missing data) rastgele degil: ortalama %38 eksik, ama eksiklik ile etiket arasinda 124 sutunda guclu korelasyon var (en guclusu gnomAD/1000 Genomes frekans ailesinde). Yani 'bu deger eksik mi' bilgisinin kendisi tahmine yardimci olabilir.
- Gen ezberi riski somut: 15 gen tek yonlu (orn. FLG/KMT2C/OBSCN hep benign, PAH/CFTR/LDLR/GLA hep pathogenic gorunuyor, n=122-144). Bu yuzden butun degerlendirmelerde 'rastgele karisim' ile 'gen bazinda ayirma (GroupKFold)' yan yana raporlanmali -- yoksa model gercekte 'gen adini ezberlemis' olabilir, biz bunu goremeyiz.
- Tek basina cok guclu ayirt edici 30 sutun bulundu (AUC>0.95) -- incelemede bunlari sizinti degil, ya bilinen guclu meta-tahminleyiciler (REVEL, AlphaMissense, MetaRNN) ya da mesru populasyon frekansi sinyali (nadir varyant = daha sik pathogenic, biyolojik olarak beklenen) oldugu goruldu.

2. Guvenilirlik/Sizinti Denetimi (NB51)

Temizlenen verinin gercekten guvenilir olup olmadigini anlamak icin 5 ayri kontrol yapildi. Amac: 'model cok iyi skor veriyor, acaba hile mi yapiyor?' sorusuna sistematik cevap bulmak.

Kontrol	Sonuc	Yorum
1. Hizli sinyal testi (tum ozellikler)	CV F1=0,9899	Cok yuksek, kirmizi bayrak (>0,97)
1b. Meta-tahminleyiciler tamamen cikarilince	CV F1=0,9878 (fark: 0,0021)	Kaynak meta-tahminleyiciler DEGIL
2. Tek-sutun AUC>0,95 olan 30 sutun	29/30 mesru	1 sutun (cardioboost) izlenecek
3. Meta-tahminleyici ablasyonu	Fark: 0,0021 (<0,05 esik)	Sinirli katkı, dusuk risk
4. Gen ezberi (GroupKFold vs rastgele)	Fark: 0,0056 (<0,10 esik)	Belirgin degil
5. Tam kopya satir kontrolu	18 kopya, 0 celiskili etiket	Temiz

En onemli bulgu: yuksek skorun kaynagi 'hile' degil, verinin dogal kalitesi

Meta-tahminleyiciler (REVEL, AlphaMissense vb. -- toplam 63 sutun) tamamen cikarilsa bile CV F1 hala 0,9878 kaliyor. Yani ~0,99'luk skor tek bir sutun grubuna bagli degil. Aciklama: 63k verisinin acik-isimli, klinik kalitede anotasyonlari (biyolojik olarak anlamlı skorlar) tek basina bile cok guclu ayirt ediciler -- bu, yarismanin anonimlestirilmis/gurultulu sutunlarindan TEMELDEN FARKLI bir veri rejimi. Genel karar: 'inceleme gerekli ama kritik sizinti bulunamadi'.

3. Sistematik Model Secimi -- H1-H8 Hipotez Testleri (NB52)

Projenin yarisma panellerinde (kucuk veri, anonim sutunlar) daha once 'kazanan' oldugu kanitlanmis 7 modelleme kararinin (H1-H8) bu buyuk, acik-isimli veri kumesinde de gecerli olup olmadigi, 7 eksen (A1-A7) sirayla test edildi. Yontem: her eksen de en iyi secenek kazanir, bir sonraki eksene sabit olarak tasinir (boylece etkiler birikir). Tum kararlar 5-kat capraz dogrulama (cross-validation) ile alindi -- test seti henuz acilmadi.

Eksen	Test edilen secenekler	Kazanan	CV F1
A1: Model ailesi	LGBM, XGBoost, CatBoost, RandomForest, BalancedBagging, NN	LGBM	0,9897
A2: Eksik veri stratejisi	flag yok, flag+medyan, secici drop, native NaN	native_nan (LGBM'e NaN'i dogrudan ver)	0,9900
A3: Sinif dengeleme	yok, class_weight, scale_pos_weight, gercek-resample	scale_pos_weight	0,9903
A4: Ozellik sayisi	tum ozellikler, top-200, top-100 (xgb onem sirasina gore)	top200	0,9904
A5: Etiket kalitesi	tumu, nitelikli-haric, guven-agirlikli, sadece-uzman-paneli	tumu (bilgi amaclı, karsilastirilamaz)	0,9904
A6: Meta-tahminleyici	dahil vs haric	dahil (fark: 0,0038)	0,9904
A7: Ozellik muhendisligi (Grantham/BLOSUM62 vb.)	yok vs var	yok (notr, -0,0007)	0,9904

H1-H8 Sonuc Karnesi

Hipotez (yarisma panelinden gelen kazanan)	63k'da sonuc
H1: BalancedBagging en guclu model	CURUTULDU -- duz LGBM kazandi
H2: Eksiklik bayragi+medyan (M3) en iyisi	CURUTULDU -- native NaN daha iyi
H3: Gercek yeniden-ornekleme class_weight'ten iyi	CURUTULDU -- scale_pos_weight kazandi
H6: Ozellik muhendisligi panele bagli	NOTR
H7: Ozellik secimi katki sagliyor	DOGRULANDI
H8: Sinir agi (NN) artik rekabetci	DOGRULANDI (fark <0,01)

En onemli bulgu: yarisma reçetesi 63k'ya AKTARILAMAZ -- iki ayri rejim

Yarisma panellerinde (kucuk veri: n~100-3000, anonim sutunlar, zayıf sinyal) kazanan reçete (BalancedBagging + eksiklik-bayragi + gercek-yeniden-ornekleme) burada UCUNUN DE tersine dondu. Sebep: 63k'da veri boyutu (~60.970 satir, yarisma panellerinin ~20 kati) ve acik-isimli guclu meta-tahminleyiciler (REVEL, AlphaMissense, gnomAD) sayesinde sinyal zaten cok guclu (floor=0,543, model=0,99); buyuk veride duz LGBM+scale_pos_weight zaten dengesizligi yonetyor, gercek yeniden-ornekleme ise veriyi bosuna israf ediyor. SONUC: iki veri rejimi arasinda reçete transferi yapilamiyor, her biri kendi rejiminde ayri ayri optimize edilmeli.

Sampiyon reçete (NB53'un baslangic noktası): LGBM + native_nan + scale_pos_weight + top-200 ozellik + meta-tahminleyici dahil + ozellik muhendisligi yok -> CV F1=0,9904, CV MCC=0,9848, gen-ezberi kontrollu F1=0,9886.

4. Ince Ayar -- Optuna, Ensemble, Kalibrasyon (NB53)


NB52'nin sampiyon reçetesi alinip 5 ek gelistirme denendi: otomatik hiperparametre aramasi (Optuna), model birlestirme (stacking), olasilik kalibrasyonu, karar esigi (threshold) secimi, ve ek veri (non-missense varyantlar) katkisi. Test seti hala kapali.

Deney	Sonuc	Karar
Optuna (100 deneme, LGBM hiperparametreleri)	CV F1: 0,9897 -> 0,9907 (+0,0010)	KABUL -- kucuk ama pozitif kazanc
Stacking H5: farkli model aileleri birbirinden farkli mi?	Maksimum ikili korelasyon = 0,9988	CURUTULDU -- modeller neredeyse ozdes tahmin veriyor
Stacking H4: meta-model GBM mi LR mi olmalı?	Meta=LR: 0,9900 Meta=GBM: 0,9906 Tekli en iyi model: 0,9907	Stacking'in kendisi GEREKSIZ (kazanc: -0,0001)
Kalibrasyon (Platt vs Isotonic)	ECE: 0,0045 -> 0,0005 (Isotonic kazandi)	KABUL -- model zaten iyi kalibreydi, kucuk iyilesme
Esik (threshold) secimi	F1-max ve MCC-max ayni noktada birlesti: 0,46	F1-max secildi (F1=0,9907, MCC=0,9852)
Non-missense veri ekleme (n=2482)	CV F1: 0,9907 -> 0,9890 (-0,0017)	REDDEDILDI -- hafif zararli

En onemli bulgu: buyuk veri + guclu sinyal rejiminde 'ensemble' teknikleri degersizlesiyor

Stacking, kalibrasyon-otesi duzeltme ve ek veri gibi teknikler yarisma panellerinde (kucuk veri, zayif sinyal) onemli kazanc sagliyordu. Burada (buyuk veri, cok guclu acik-isimli sinyal, CV F1 zaten ~0,99) hicbiri katki saglamadi -- cunku bu tekniklerin ise yaramasi icin gereken on kosullar (modeller arasi cesitlilik, kalibrasyon bozuklugu, ekstra sinyal) burada mevcut degil. Tek gercek kazanc kaynagi Optuna oldu, o da marjinal (+0,0010).

Sampiyon reçete v2 (NB54'e tasinan nihai reçete): LGBM + Optuna parametreleri + native_nan + scale_pos_weight + top-200 ozellik + meta-tahminleyici dahil + ozellik muhendisligi yok, stacking KULLANILMIYOR, kalibrasyon=isotonic, esik=0,46. Nihai CV F1 = 0,9907.



Sekil 1: NB53 optimizasyon asamalarinin CV F1 ilerlemesi

5. Nihai Degerlendirme -- Test Seti Ilk ve Son Kez Aciliyor (NB54)

Bu asamaya kadar (NB50-53) tum kararlar 5-kat capraz dogrulama ile alindi; ayrilmis, hic dokunulmamis bir test bolumu YOKTU. NB54'te ilk kez stratified train/test ayrimi yapildi (egitim: 48.776 satir, test: 12.194 satir, her ikisi de %37,3 pathogenic oraninda) ve reçete SABIT tutularak model sadece egitim verisiyle yeniden egitildi, test seti YALNIZCA BIR KEZ, sonuclari degistirmeden degerlendirmede kullanildi. Bu, gercek dunya performansinin en durust tahminidir.

5.1 Nihai test metrikleri

Metrik	Egitim (train)	Test (hold-out, ilk kez)
F1 (pathogenic)	1,0000	0,9902
Precision	1,0000	0,9899
Recall	1,0000	0,9905
MCC	1,0000	0,9844
AUC-ROC	1,0000	0,9945
AUC-PR	1,0000	0,9889
Specificity	1,0000	0,9940
Balanced Accuracy	1,0000	0,9923

Confusion Matrix (test, n=12.194): Dogru negatif (benign->benign)=7.604, Yanlis pozitif (benign->pathogenic hatasi)=46, Yanlis negatif (pathogenic->benign hatasi, en riskli hata tipi klinik acidan)=43, Dogru pozitif (pathogenic->pathogenic)=4.501.

Floor-F1 karsilastirmasi (trivial model kontrolu)

Test setinin floor-F1'i (hep pathogenic tahmin etme stratejisi) = 0,5430. Model F1'i 0,9902 -- floor'un +0,4473 UZERINDE. Bu, modelin gercekten anlamlı bir sey ogrendigini, taban stratejiye esdeger olmadigini gosteriyor (yarisma panellerinden PAH'ta karsilasilan 'model tavana esit, aslinda trivial' sorununun burada yasanmadigi anlamina gelir).

5.2 Protokol durustlugu -- CV tahmini gercegi ne kadar yansitti?

NB53'un 5-kat CV F1'i (0,9907, model gelistirilirken kullanilan tahmin) ile NB54'un gercek hold-out test F1'i (0,9902, modelin daha once hic gormedigı veri) arasindaki fark = +0,0005. Bu, capraz dogrulamanin asiri iyimser olmadigini, gercek performansi guvenilir sekilde tahmin ettigini kanitlar (bazi projelerde CV skoru gercek test skorundan cok yuksek cikar, bu 'sizinti' veya 'asiri uyum' isaretidir -- burada gorulen fark cok kucuk oldugu icin protokol SAGLAM kabul edildi).

5.3 Gen ezberi kontrolu -- model gen adini mi ezberledi, biyolojiyi mi ogrendi?

Egitim verisi uzerinde gen-bazli ayirma (GroupKFold, ayni genin bir satiri egitimde ise digerleri de mutlaka ayni tarafta kalir -- Boylece model 'bu gen hep pathogenic' seklinde ezberleyip haksiz avantaj kazanamaz) ile rastgele ayirma karsilastirildi:

Degerlendirme yontemi	F1
Rastgele hold-out test (yukaridaki nihai sonuc)	0,9902
Gen-bazli ayirma (GroupKFold, ayni egitim seti uzerinde)	0,9881

Fark: +0,0021 (rastgele lehine) -- ihmal edilebilir duzeyde kucuk. Karar: 'belirgin gen ezberi yok', NB51'deki onceki bulguyla (fark 0,0056) tutarli. Model, spesifik gen adlarini ezberlemek yerine genellenebilir biyolojik ozellikleri ogreniyor gibi gorunuyor.


6. Model Neye Bakiyor? -- SHAP Yorumlanabilirlik Analizi

63k veri kumesinin en buyuk avantajı, sutun isimlerinin acik olmasi (yarisma verisindeki anonimlestirilmis sutunlarin aksine) -- bu sayede modelin hangi biyolojik sinyale dayandigi dogrudan incelenebilir. SHAP (SHapley Additive exPlanations) yontemiyle her ozelligin tahmine ortalama katkisi olculdu (test setinden 5.000 ornek uzerinde).

Sira	Ozellik	Ortalama SHAP	Aciklama
1	ditto__score	4,41	DITTO: derin ogrenme tabanli patojenite skoru
2	metarnn__score	1,25	MetaRNN: meta-tahminleyici (coklu skoru birlestiren model)
3	allofus250k__gvs_max_af	0,77	All of Us kohortu populasyon frekansi
4	gnomad__af	0,76	gnomAD populasyon frekansi (nadir=pathogenic egilimi)
5	metarnn__rank_score	0,68	MetaRNN skorunun normalize sirasi

Beklenmedik ama makul bulgu: DITTO, REVEL/AlphaMissense'i acik farkla geride birakti


Plan asamasinda REVEL/AlphaMissense/CADD gibi daha taninmis skorlarin tepede cikmasi bekleniyordu; onlarin yerine DITTO skoru (ikinci siradaki MetaRNN'in ~3,5 kati agirlikta) baskin cikti. Bu supheli degil -- DITTO da bilinen, gecerli bir derin-ogrenme tabanli patojenite tahminleyicisi; modelin ona daha cok agirlik vermesi, bu spesifik veri kumesinde DITTO'nun diger skorlarla orduse (redundant) olmadan ek ayirt edicilik sagladigini gosteriyor. gnomAD/AllofUs populasyon frekansi sutunlarinin da ust siralarda olmasi biyolojik olarak beklenen bir durum: nadir varyantlar hastalik yapici olma egilimindedir.



Sekil 2: Test setinde en etkili 30 ozellik (ortalama |SHAP| degeri)

6.1 Hata analizi -- model nerede yaniliyor?

Test setindeki 12.194 tahminden sadece 89 tanesi yanlis (46 yanlis-pozitif + 43 yanlis-negatif). Bu hatalar gen bazinda gruplandirildiginda, herhangi bir genin hatalarin cogunlugunu olusturmadigi gorulduu -- en cok hata veren genler (RYSR1, KAT6B, MSH2, BRCA1 - yanlis pozitifte; TP53, DYNC2H1, ACADM - yanlis negatifte) her biri sadece 1-2 hataya sahip. Bu, modelin sistematik olarak belirli bir gen ailesinde zayif olmadigini, hatalarin dagilmis/rastgele oldugunu gosteriyor -- yapisal bir kusurdan cok, sinir vakalarindaki (borderline) dogal belirsizligi yansitiyor.



Sekil 3: Egitim vs test metrikleri ve rastgele-vs-gen-holdout F1 karsilastirmasi

7. Genel Sonuc ve Model Teslimi

63k genis veri hattinin (NB50->NB54) sonunda ortaya cikan model, hicbir sekilde daha once gorulmemis bir test bolumu uzerinde $F1=0,9902$, $MCC=0,9844$ skorlariyla degerlendirildi. Bu, taban stratejinin (floor- $F1=0,5430$) cok uzerinde, egitim-test farki ihmal edilebilir duzeyde (protokol saglam), ve gen ezberi riski dislanmis bir sonuctur.

Nihai model reçetesi (ozet)

- Algoritma: LightGBM (gradient boosting)
- Hiperparametreler: Optuna ile 100 denemede optimize edildi (num_leaves=150, max_depth=4, learning_rate=0,115, n_estimators=488)
- Eksik veri: modelin kendi native NaN islemesine birakildi (ayri imputation yok)
- Sinif dengesizligi: scale_pos_weight ile yonetildi
- Ozellik sayisi: 533 ozellikten en onemli 200'u secildi
- Meta-tahminleyiciler (REVEL, AlphaMissense vb.): dahil edildi
- Ozellik muhendisligi (Grantham/BLOSUM62): kullanilmadi (test edildi, katkı saglamadi)
- Kalibrasyon: Isotonic regresyon (olasilik tahminlerini daha guvenilir hale getirir)
- Karar esigi: 0,46 ($F1$ -max ve MCC -max ayni noktada birlesti)
- Ensemble/stacking: KULLANILMADI -- test edildi, tekli model daha iyi cikti

Bu calismanin metodolojik degeri: '63k rejimi' ile 'yarisma paneli rejimi' arasindaki fark

Bu bes notebook'un en onemli katkisi sadece nihai $F1=0,99$ skoru degil, ayni zamanda 'buyuk, acik-isimli, guclu-sinyalli veri' ile 'kucuk, anonim, zayif-sinyalli veri' arasinda modelleme stratejisinin KOKTEN farkli olmasi gerektigini sistematik olarak kanitlamis olmasidir. Yarisma panellerinde is goren teknikler (BalancedBagging, eksiklik-bayragi, gercek yeniden-orneklem, stacking, kalibrasyon-sonrasi duzeltme) burada ya ise yaramadi ya da hafif zararli cikti. Bu iki veri kumesi arasinda reçete kopyalamanin yanlis oldugu, her rejimin kendi ozel kosullarina gore ayri ayri test edilmesi gerektigi bu calismayla acikca gosterilmis oldu.

Kaydedilen artifact'lar

models/v31_63k/: nihai model (joblib), isotonic kalibrator, kategorik encoder, ve tum model parametrelerini/metriklerini iceren manifest dosyasi.

results/v35_63k_final/: split indeksleri, SHAP tablosu/grafigi, hata analizi CSV'leri (FP/FN gen bazinda), final ozet grafigi.

Bu model, projenin gercek yarisma teslim hattindan (NB12-NB48, ayri kalmaya devam ediyor) BAGIMSIZ bir arastirma/karsilastirma hattidir.