

Parametreler

Sütun adlarında anonimleştirilme yapılmış:

- **Variant_ID:** Her satırdaki varyantın benzersiz kimliği. **Model girdisi olarak kullanılmamalı.**
- **Label:** Hedef sınıf. Tüm dosyalarda 0/1 ikili sınıflama etiketi.
- **AL_1–AL_334:** Sayısal anotasyon/özellikler. Bunların bir kısmı sürekli skor veya frekans gibi davranıyor, çoğu 0 ile 1 arasında. Bir kısmı ise ikili ya da düşük kardinaliteli bayrak değişkeni gibi. **Bunlar çıkarılmalı, 0-1 arasında olanlar, flag gibi davrananlar**
- **CAT_1:** gnomAD benzeri popülasyon (gnomADe_NFE, gnomADg_NFE, gnomADe_AFR, gnomADe_EAS)
- **CAT_2:** All of Us popülasyon içeriyor (AllofUs_EUR, AllofUs_AFR, AllofUs_AMR, AllofUs_EAS)
- **CAT_3, CAT_4, CAT_5:** Genotip/nükleotid formatı(A/A, C/C, G/G, T/T, ./..) MASTER’da CAT_3 ile CAT_5 birebir aynı görünüyor. **Detaylı bakılmalı, birbirinin aynı olanlar var mı ?**
- **CAT_6:** Genomik bölge kalitesi/tekrarlı bölge bayrağı (segdup, lcr, decoy&segdup). Çok seyrek dolu.
- **EK_1–EK_9:** Ek sayısal skorlar. Bazılarında negatif değerler var; bu nedenle frekans değil, daha çok etki/patojenite/istatistiksel skor tipi değişkenler gibi görünüyor.
- **AA_1, AA_2:** Amino asit harfi (R, L, G, P, D, V).

Satır sayıları: MASTER 2931, KANSER 388, PAH 372, CFTR 111.

Sınıf dağılımı dengesiz: CFTR’de 90/21, KANSER’de 268/120, PAH’ta 310/62, MASTER’da 2149/782.

Tespitler

- Eksik değerler rastgele değil, büyük bloklar halinde silme gibi görünüyor
- Çok sayıda sabit veya birebir aynı sütun var. **Bunların tespit edilmesi gerekiyor, hangileri**
- Bazı sütunlar neredeyse tamamen boş. Bazı eksiklik desenleri hedef sınıfla ilişkili gibi görünüyor. Örneğin KANSER dosyasında AL_16–AL_25 için eksiklik oranı Label 0’da yaklaşık %29 iken Label 1’de yaklaşık %86. **Bu model için bir girdi olabilir, denemek lazım.**

Benim yorumum: Sayısal değerlere açıkça gürültü eklenmiş gibi görmedim, en büyük risk eksiklik örüntüsünün sınıf etiketiyle ilişkili olmasıdır. **Dikkate alacağız mı almayacağız mı ?**

Eksik veri doldurma önerim

Tek tip ortalama/medyan doldurma yeterli olmaz. Çünkü eksiklikler rastgele değil, panele ve etikete bağlı. Bu nedenle değişik uygulamalar yapmak gerekiyor:

1. **Eksiklik göstergesi ekleme:** Her sayısal sütun için is_missing_AL_x gibi bayrakla eksikliğin taşıdığı bilgiyi kullanma
2. **Sayısal değişkenler:** Median
3. **Kategorik değişkenler:** MISSING veya UNKNOWN (N/A) kolonu açılıp ayrı bir özellik olarak 'yok' bilgisi türetme yapılmalı
4. **Yüksek eksiklikli değişkenler:** %80 eksik olanları doğrudan doldurup kullanmanın yanı sıra madde 1-3 denenerek karar verilmeli.

ÖNEMLİ NOT: **IMPUTASYON TÜM VERİYE YAPILMAZ TRAIN AYRILDIKTAN SORA YAPILIR, siz nasıl yaptınız**

MODELLEME'de dikkat edin !!

- 1- Güçlü baseline için SVM, DNN, CatBoost, LightGBM veya XGBoost kullanın
- 2- Ablasyonu CAT tamamen dışarıda ya da AL gibi yapamazsınız, tek tek çalışmak lazım.
- 3- Stacking ve MoE veya derin öğrenme uygulanacaksa median/mode imputation + missing
- 4- **Sabit sütunlar:** Her panelde tek değerli sütunlar var. Bunlar bilgi taşımaz. Bunlar dahil hariç model üretilmeli.
- 5- **Birebir aynı sütunlar:** MASTER'da çok sayıda aynı sütun çifti var. En azından birebir duplicate sütunların biri bırakılmalı.
- 6- **Aşırı eksik sütunlar:** Özellikle AL_1–AL_6, AL_27–AL_38, CAT_6 gibi %80–95+ eksik sütunlar dikkatli ele alınmalı. Bunları ya sadece eksiklik bayrağı olarak kullanacağız ya da çıkaracağız ablation ile test edin.
- 7- :Eğer yarışma test setinde aynı eksiklik mekanizması yoksa, bu imputasyon yöntemi ya da eksiklik bayrağı kullanımı risk demektir. Elimizde birden çok model olmalıdır. İmalı.

MoE için önerim:

- **Uzman 1, ana anotasyon uzmanı:** Düşük/orta eksiklikli AL_* sayısal değişkenleri kullanan LightGBM/CatBoost uzmanı.
- **Uzman 2, popülasyon/kategorik uzmanı:** CAT_1, CAT_2, CAT_3–CAT_6, AA_1, AA_2 üzerine odaklanan CatBoost uzmanı.
- **Uzman 3, EK skor uzmanı:** EK_1–EK_9 skorlarını kullanan küçük ve düzenleştirilmiş model.
- **Uzman 4, eksiklik deseni uzmanı:** Sadece missing mask sütunlarını kullanan model. Bu uzman ayrıca leakage riskini ölçmek için diagnostik amaçlı kullanılmalı.
- **Gating modeli:** Panel tipi, eksiklik oranı, dolu blok sayısı, CAT varlığı gibi meta-özelliklerle uzman ağırlıklarını belirlemeli. Panel tipi dosya adından biliniyorsa CFTR/KANSER/PAH için ayrı uzman ağırlıkları öğrenilebilir.
- **Eğitim stratejisi:** MASTER ile genel uzmanları eğitip, CFTR/KANSER/PAH panellerinde fine-tune veya stacking yapılabilir. Ancak panel dosyaları MASTER ile kısmen örtüşüyor; aynı Variant_ID train/validation arasında sızmamalı.

Benim pratik başlangıç önerim: önce CatBoost/lightgbm/XB + missing category + median imputation baseline kurun; sonra numeric, categorical/AA, EK, missing-mask olmak üzere dört uzmanlı stacking/MoE deneyin. En kritik kontrol, eksiklik maskesi olmadan ve eksiklik maskesiyle performans farkını ölçmek olacaktır.