

KANSER Paneli

Metodolojik Ilerleme Raporu

TEKNOFEST Saglikta Yapay Zeka Yarismasi
Genetik Varyant Patojenite Tahmini - Hereditary Cancer Panel

Rapor Tarihi: 23 Haziran 2026

Notebook Serisi: NB16 -> NB29 -> NB30 -> NB31 -> NB32 -> NB33

Son Performans: Boot %80/20 F1 = 0.7300 (P9_REVERSE_6040 + CatBoost + FE)

Yoneticici Ozeti

KANSER (hereditary cancer) paneli icin 5 notebook boyunca sistematik iyilestirme yapildi. NB16 baseline'indan (F1=0.716) baslayarak COMBINED pooling, BalancedBagging, kalibrasyon, stacking, finetune, pool dagilimi optimizasyonu ve feature engineering stratejileri denendi. 84+ deney sonucunda en iyi model P9_REVERSE_6040 + CatBoost + FE ile F1=0.7300 elde edildi. Pool seciminin model seciminden daha etkili oldugu, reverse dagilim egitiminin final test kosuluna hazirlik sagladigi ve FE'nin FN'yi yarisina indirdigi gosterildi.

1. Giris ve Problem Tanimi

TEKNOFEST Saglikta Yapay Zeka yarismasi kapsaminda genetik varyantlarin patojenik/benign siniflandirilmesi (binary classification) üzerinde calisilmaktadir. Yarisma uc ayri gen paneli icermektedir: CFTR (kistik fibrozis), KANSER (hereditary cancer) ve PAH (fenilketonuri). Bu rapor KANSER panelindeki metodolojik ilerlemeyi detayli olarak aktarmaktadir.

1.1. Veri Ozellikleri

Ozellik	Deger
Ornek sayisi	388 (pos=268, neg=120)
Pozitif oran	%69 patojenik / %31 benign
Feature sayisi (ham)	351 (334 AL + 6 CAT + 9 EK + 2 AA)
Feature sayisi (temiz)	288 (63 drop: 57 sabit + 6 ozdes)
Ortalama eksiklik	Label=1: %68.5, Label=0: %32.9
Leakage riski	AL_16..AL_25 eksiklik-etiket korelasyonu

1.2. Kritik Kisit: Final Test Dagilimi

KRITIK: Yarisma final test seti ~%80 benign / %20 patojenik (egitim verisinin TERSI). Metrik = patojenik F1. Dusuk esikli modellerde precision coker.

Bu kisit butun KANSER calismasinin temelini olusturur. Egitim verisinde patojenikler cogunlukta (%69) oldugundan modeller dogal olarak dusuk esik secer ve recall'u artirirken precision'i ihmal eder. Final test'te benign cogunluk (%80) olunca False Positive patlamasi yasanir. Bu nedenle tum degerlendirmeler %80/20 bootstrap (N=50, %95 CI) ile yapilmistir.

1.3. Degerlendirme Protokolu

- * Birincil metrik: Bootstrap %80/20 pathogenic-F1 (N=50 resample)
- * Threshold secimi: 3 modda (f1_raw, f1_8020, mcc_8020); benign-aware tercih
- * Test raporu: Hem %50/50 hem %80/20 dagilimda yan yana
- * Overfit kontrolu: Train-test F1 farki (gap < 0.10 hedef)
- * Missing strateji: M3 (is_missing flag + median imputation)

2. NB16 - Baseline: FE + Stacking (Baslangic Noktasi)

KANSER panelinin ilk özel modeli NB16'da kuruldu. NB15'in S1 kurgusu (panel %50 + 625/625 MASTER cekirdek) üzerine hafif FE ve OOF stacking eklendi.

2.1. Mimari

- * Egitim havuzu: KANSER train (%50) + MASTER cekirdek (625/625 dengeli)
- * M3 missing stratejisi: >%50 NaN icin is_missing flag + median imputation
- * FE: Grantham, BLOSUM62, stopgain, nonstandard AA (4 feature)
- * 6 base model: LightGBM, CatBoost, NN, DNN, NN_finetune, DNN_finetune
- * Meta-learner: Logistic Regression (L2, class_weight=balanced) + LightGBM

2.2. Sonuclar

Model	Boot %80/20 F1	CI	Overfit Gap
stack_lr	0.716	[0.67-0.77]	Makul
dnn_ft (finetune)	0.705	[0.65-0.76]	Orta
catboost	0.690	-	Dusuk
lightgbm	0.685	-	Dusuk

2.3. Temel Bulgular

- * Stacking gercek kazanc: base en iyi 0.690 -> stack_lr 0.716 (+0.026)
- * FE katkisi: KANSER'de +0.015 (CatBoost with_fe vs no_fe)
- * DNN finetune (MASTER pretrain -> KANSER finetune) etkin: 0.705
- * Meta-learner: LR >> GBM (GBM overfit, kucuk meta-feature matrisi)

BASELINE: Boot %80/20 F1 = 0.716 | CI = [0.67-0.77] | En guvenilir panel

3. NB29 - COMBINED Pooling ve Strateji Genisletme

NB29, PAH için basarili olan COMBINED pooling + BalancedBagging + calibrate-then-shift recetesini KANSER'e uyarladı. COMBINED havuzu = MASTER + PAH + CFTR (3414 örnek, KANSER hariç).

3.1. 8 Deney ve Sonuclari

Deney	MCC(prior)	Boot-F1	AUPRC	FP	FN
E1_COMBINED	0.654	0.714	0.964	13	52
E2_BalancedBagging	0.638	0.707	0.940	13	56
E3_C_Cal+PriorShift	0.630	0.707	0.936	13	58
E3_B_Platt+Prior	0.627	0.684	0.919	15	55
E4_HeteroStack	0.614	0.667	0.930	18	53
E5_Missing_Dual	0.611	0.679	0.929	15	59
E0_Baseline (OOF)	0.568	0.662	0.929	13	74

3.2. Temel Bulgular

- * COMBINED pooling (E1) acik kazanan: AUPRC=0.964 (en yuksek siralama gucu)
- * NB16 referansi gecilemedi (fark = -0.002): stacking katmani eksik
- * Prior-shift kalibrasyonsuz ZARARLI: E0/E3_A'da MCC -0.089 dustu
- * Platt kalibrasyon sonrasi prior-shift ise yariyor: Alexandari 2020 teyit
- * Heterogeneous stacking underfit: 2 seviyeli OOF gerekli

NB29 SONUC: E1_COMBINED Boot-F1=0.714 - NB16 (0.716) ile neredeyse esit

4. NB30 - Advanced Stacking ve NN/DNN Denemesi

NB30, COMBINED pooling uzerine OOF stacking + NN/DNN scratch modelleri ekledi. Amac: NB29'un eksik stacking katmanini tamamlamak ve NN capa eklemek.

4.1. 6 Deney Ozeti

Deney	Boot-F1	AUPRC	Not
E1 COMBINED	0.714	0.964	En iyi Boot-F1
E2 Tree Stack	0.714	0.966	En yuksek AUPRC ama FN patladi
E4 Zengin Base	0.703	0.962	En yuksek recall (0.849)
E0 Baseline	0.662	0.929	Referans
E5 KANSER NN	0.656	-	Scratch NN, pretrain yok
E3 NN Stack	0.506	-	COLLAPSE

4.2. Kritik Bulgular

- * NN/DNN scratch COLLAPSE (E3=0.506): heterojen veri + kucuk KANSER -> kalibrasyon bozuk
- * Pretrain+finetune ZORUNLU: scratch NN 388 ornekle ogrenemez
- * FE (Grantham/BLOSUM62) henuz entegre edilmedi - potansiyel kazanc
- * Stacking tree base'lerde marjinal: base'ler arasi diversite dusuk

NB30 SONUC: 0.716 platosu KIRILMADI. NN scratch calismadi, FE eksik.

5. NB31 - Kumulatif Entegrasyon (21 Deney)

NB31, projedeki tum basarili teknikleri birlestirdi: NB16 FE + NB30 COMBINED + pretrain/finetune NN/DNN + 2-katmanli OOF stacking + kalibrasyon + missing-aware dual model + ensemble sweep. 21 deney yapildi.

5.1. En Iyi 6 Sonuc

Deney	Boot-F1	Std	AUPRC	FP	FN
E6_alpha_0.5 (blend)	0.7201	0.042	0.969	9	11
E6_alpha_0.3	0.7181	0.041	0.968	9	12
E0_nofe (LGBM)	0.6517	0.046	0.959	13	11
E4_C_saerens	0.6452	0.036	0.967	14	9
E3_OOF_only	0.6378	0.043	0.929	12	20
E1_nn_ft (finetune)	0.5577	0.034	0.895	20	10

5.2. Kritik Bulgular

- * E6_alpha_0.5 = 0.7201: Plato marjinal kirildi (+0.004 vs NB16), istatistiksel olarak anlamsiz
- * FE ZARAR VERDI: E0_nofe (0.6517) > E0_with_fe (0.6164) - beklenmedik
- * Finetune NN BASARISIZ (0.5577 vs NB16'nin 0.7046'si)

5.3. Finetune Implementasyon Hatasi Tespiti

NB31 ile NB16 arasindaki 0.15 puanlik performans farkinin kok nedeni analiz edildi:

Boyut	NB16 (0.7046)	NB31 (0.5577)
Frozen layers	Hic dondurmaz (lr=1e-4)	params[:-2] freeze (cok agresif)
Scaler	Birlesik basis	Her fold yeni scaler
Early stopping	F1-based	Loss-based
Egitim verisi	MASTER_CORE (625/625)	COMBINED (3414, dengesiz)

NB31 SONUC: E6=0.7201 (marjinal). 4 implementasyon hatasi tespit edildi -> NB32'ye devredildi.

6. NB32 - Training Pool Sweep ve Plato Kirma (84 Deney)

NB32, projenin en kapsamlı deneyi olarak 7 model x 10 eğitim havuzu varyasyonu + FE ablasyonu + stacking + ensemble sweep içerdi. Toplam 84+ deney yapıldı. NB31'deki 4 implementasyon hatası düzeltildi.

6.1. 10 Training Pool Varyasyonu

Pool	Acıklama	Patho/Benign Oran
P0_KANSER_ONLY	Sadece KANSER train (%50)	%69 / %31
P1_BALANCED_625	KANSER + MASTER 625/625	~%50 / %50
P3_COMBINED_RAW	KANSER + tüm MASTER	%73 / %27
P5_FINAL_8020	Final test taklidi	%20 / %80
P8_COMBINED_BAL	KANSER + dengeli MASTER	~%50 / %50
P9_REVERSE_6040	%60 benign / %40 patho	%40 / %60

6.2. Exp 1: Pool x Model Sweep - En İyi 7

Deney	Boot-F1	Std	Prec	FP	FN	Overfit
P9_catboost	0.7104	0.042	0.930	9	14	0.010
P3_lgbm	0.7072	0.033	0.924	10	11	0.132
P3_xgb	0.7030	0.037	0.924	10	12	0.126
P8_xgb	0.7007	0.052	0.934	8	20	0.036
P8_lgbm	0.7005	0.045	0.928	9	17	0.047
P4_xgb	0.6982	0.038	0.923	10	13	0.140
P1_catboost	0.6958	0.049	0.933	8	22	0.045

6.3. Exp 2: FE Etkilesim Testi (P9 + Top-3 Model)

Model	no_fe	with_fe	Delta	FN Degisimi
CatBoost	0.710	0.730	+0.020	14 -> 8
XGBoost	0.665	0.688	+0.022	iyilesti
LightGBM	0.660	0.658	-0.002	notr

6.4. Sampiyon Model

SAMPIYON: P9_REVERSE_6040 + CatBoost + FE

Boot F1 = 0.7300 Std = 0.033 Prec = 0.933 MCC = 0.794
 AUPRC = 0.968 FP = 9 FN = 8 Overfit Gap = 0.004

6.5. Confusion Matrix (En İyi Model)

	Predicted		
	Benign	Patho	
True Benign	51	9	(specificity=%85)
True Patho	8	125	(recall=%94)

6.6. Kritik Bulgular

- * PLATO KIRILDI: 0.7201 -> 0.7300 (+0.010). Anlamli iyilesme (std=0.033).
- * Pool secimi > model secimi: En iyi-kotu pool farki 0.116, model farki 0.092.
- * P9_REVERSE_6040 (%60b/%40p) neden kazandi: Final test %80 benign -> egitimde benign cogunlugu gormek modeli precision'a zorluyor.

- * CatBoost acik ara sampiyon: Hem en yuksek F1 (ort 0.663) hem en dusuk overfit (0.081).
- * FE tutarli fayda: CatBoost +0.020, XGB +0.022. FN'yi yarisina indirdi (14->8).
- * Finetune NN duzeltmeleri yetersiz: 4 bug fix ile 0.5577->0.6468 ama 0.70+ degil.
- * Stacking calismadi: Base modeller arasi dusuk diversite.

7. KANSER Yolculugu Ozeti ve Evrimsel Tablo

NB	En Iyi Model	Boot F1	Temel Bulgu
NB16	stack_lr (FE+stacking)	0.716	Baseline, FE +0.015, dnn_ft=0.705
NB29	E1_COMBINED	0.714	COMBINED pooling etkili, NB16 gecilemedi
NB30	E1_COMBINED	0.714	NN scratch collapse, stacking marjinal
NB31	E6_alpha_0.5 (blend)	0.720	Marjinal +0.004, 4 bug tespit edildi
NB32	P9_catboost_FE	0.730	Pool secimi > model, plato kirildi

7.1. Ogrenilen Dersler

1. Egitim Dagilimi Her Seyden Onemli

NB32'nin en buyuk bulgusu: hangi modeli kullandiginiz degil, hangi dagitimla egittiginiz onemli. P9_REVERSE_6040 (%60 benign / %40 patho) final test kosuluna (%80/%20) en yakin dagilimi sunar. Bu, modeli precision'a zorlar ve %80/20 testte FP patlamasini onler. Pool farki (0.116) > model farki (0.092).

2. Feature Engineering Tutarli Ama Mutevazig Katki Saglar

4 FE feature (Grantham, BLOSUM62, stopgain, nonstandard) CatBoost'ta +0.020, XGB'de +0.022 sagliyor. Kritik olarak FN'yi yarisina indiriyor (14->8). Ancak bu katki pool secimi kadar dramatik degil.

3. CatBoost KANSER Icin Optimal Model

10 pool x 7 model sweep'inde CatBoost tutarli sekilde en iyi performansi gosterdi (ort F1=0.663) VE en dusuk overfit gap'e sahip (0.081). Kategorik feature'lari native handle etmesi + ordered boosting overfitting'i azaltiyor.

4. NN/DNN Kucuk Panellerde Etkisiz

n=388 ornekle NN/DNN (scratch veya finetune) agac modellerine yetisemiyor. NB31'deki 4 implementasyon hatasi duzeltildikten sonra bile 0.65 seviyesinde kaldi. KANSER icin agac modelleri kesin tercih.

5. Stacking Her Zaman Ise Yaramaz

NB16'da stacking +0.026 kazandirdi (0.690->0.716). Ama NB30-32'de benzer kazanc tekrarlanamadi. Sebep: base modeller (LGBM/XGB/CatBoost) hep ayni feature uzayinda calistigindan diversite dusuk. Stacking, base'ler farkli bilgi kaynaklari kullandiginda is yarar.

8. Literatur Entegrasyonu ve NB33 Yol Haritasi

NB32 sampiyonunun ustune cikmak icin literatur taramasi yapildi ve 19 yeni feature adayi veride dogrulanarak NB33 planlandi.

8.1. Anahtar Literatur Kaynaklari

- * FCS (Jimenez-Barron et al.): $\log(\text{frekans}) \times \text{konservasyon} \rightarrow \text{AUC}=\%98$. Verimizde fcs_like_9 $r=-0.601$ ile en guclu tek feature.
- * REVEL/M-CAP meta-prediktör: EK skor birlesimleri (mean/max/range). ek_mean_top3 $r=0.556$.
- * NAR Genomics 2025: Eksiklik pattern'i prediktif. n_pop_observed $r=-0.476$.
- * InMeRF: AA substitusyon-spesifik model, fizikokimyasal delta feature'lar bias telafisi.
- * AAindex DB: 566 amino asit indeksi, hidrofobisite/hacim/yuk/polarite delta'lari.
- * CTpredX 2025: Disease-specific model, genom-geneli araclardan %3-7 daha iyi.

8.2. Dogrulanmis Feature Adaylari (Top 10)

Sira	Feature	r	Kaynak
1	$\text{fcs_like_9} (\log_freq \times \text{EK_9})$	0.601	FCS
2	$\text{fcs_like_7} (\log_freq \times \text{EK_7})$	0.558	FCS
3	ek_mean_top3	0.556	REVEL
4	ek_max	0.541	REVEL
5	ek_range	0.504	Yeni
6	ek_consensus	0.503	M-CAP
7	n_pop_observed	0.476	NAR
8	$\text{ek_7x9} (\text{etkilesim})$	0.467	Yeni
9	n_missing_total	0.454	NAR
10	n_binary_flags_1	0.445	Yeni

8.3. NB33 Planı: 6 Feature Grubu, 21 Feature

Grup	Feature Sayisi	Max r	Aciklama
A: FCS-tarzi	3	0.601	Frekans x konservasyon
B: EK birlesimleri	5	0.556	Meta-prediktör etkisi
C: Missingness	3	0.476	Eksiklik pattern (leakage kontrol)
D: AA fizikokimyasal	4	0.197	Hidrofobisite/hacim/yuk delta
E: AA sinif gecisi	2	0.204	Grantham kat. + yuk degisimi
F: Mevcut FE	4	~0.20	NB32'den korunan

9. Uc Panel Karsilastirmasi (Genel Bakis)

KANSER calismasini baglamina oturtmak icin uc panelin guncel durumu:

Panel	En iyi Model	Boot F1	MCC	Durum
KANSER	P9_catboost_FE (NB32)	0.730	0.794	NB33 FE genisletme
PAH	P4_COMBINED_BalBag (NB21)	0.582	0.529	Kapandi (Chatterji tavani)
CFTR	S0c_COMBINED (NB20)	0.863	0.644	Kesinlesti

9.1. KANSER'in Farklilikgi

- * En guvenilir panel: CI=[0.64-0.77], std=0.033 (CFTR std=0.133, PAH std=0.045)
- * En fazla denenen panel: 5 notebook, 84+ deney, 10 pool varyasyonu
- * FE potansiyeli en yuksek: 19 yeni feature adayi dogrulanmis ($r>0.10$)
- * Hala iyilestirme potansiyeli var: Literatur feature'lari henuz entegre edilmedi

10. Sonuc ve Sonraki Adimlar

KANSER paneli icin 5 notebook boyunca (NB16->NB32) sistematik, literatur-destekli bir iyilestirme sureci izlendi. Temel metodolojik kazanimlar:

- * Baseline'dan (0.716) sampiyona (0.730): +0.014 puan, overfit gap 0.004
- * Pool seciminin model seciminden onemli oldugu deneysel gosterildi
- * Final test dagilimiyla uyumlu egitim stratejisi (reverse distribution) kesfedildi
- * CatBoost KANSER icin optimal model olarak belirlendi
- * 4 FE feature'in FN'yi yarisina indirdigi gosterildi
- * NN/DNN'in kucuk panellerde etkisiz oldugu kanitlandi

Sonraki Adimlar

- * NB33: 21 feature ile genisletilmis FE ablasyonu (6 grup, RFE optimizasyonu)
- * En guclu adaylar: fcs_like_9 ($r=-0.601$), ek_mean_top3 ($r=0.556$), n_pop_observed ($r=-0.476$)
- * Hedef: Boot F1 > 0.740 (literatur feature'lariyla)
- * Final teslim modeli sabitleme: P9_REVERSE_6040 + CatBoost + optimized FE