

NB50 - 63k Genis Veri Hazirlama & EDA Raporu

1. Veri Ozeti

Kaynak dosya: data/63k_genis/full_cravat_v3_63k.csv

Toplam satir: 63463

Etiketlenen satir: 63452

Disillanan (belirsiz etiket): 11

Missense satir (ana set): 60970

Non-missense satir (ayri parquet): 2482

2. Sizinti Temizligi

Sizinti temizligi oncesi sutun: 781

Drop edilen (clinvar + id/text/transcript): 170

Sizinti temizligi sonrasi sutun: 611

Sabit sutun (drop): 70

Ozdes sutun cifti (drop): 3

Final sutun sayisi: 538

Meta-predictor skor sutunlari (ayri tutuldu): 27

3. Sinif Dengesi ve Floor-F1

Prevalans (patho): 0.3727

FLOOR-F1: 0.5430

Majority-class accuracy baseline: 0.6273

4. Eksiklik Profili

Ortalama eksiklik (numeric+binary): 0.3799

>%50 eksik sutun sayisi: 117

MNAR gucunde sutun sayisi ($|\phi| > 0.1$): 124

MNAR/MCAR sonucu: MNAR (Label ile iliskili)

5. Sizinti Riski Sinyali (NB51 icin on-bulgu)

Tek-degiskenli AUC>0.95 sutun sayisi: 30

Not: Kesin karar NB51 sizinti denetiminde verilecek

6. Yarisma Verisiyle Karsilastirma

Yarisma (MASTER, anonim)

n: 2931

prevalence_patho: 0.733

floor_f1: 0.846

ortalama_eksiklik: 0.55

feature_sayisi: 351

yorumlanabilir: Hayir

63k (missense, legacy)

n: 60970

prevalence_patho: 0.3727

floor_f1: 0.543

ortalama_eksiklik: 0.3799

NB50 - 63k Genis Veri Hazirlama & EDA Raporu

feature_sayisi: 527

yorumlanabilir: Evet (SHAP)