

Pretrain -> Finetune ve Cross-Panel Transfer Ogrenme Deneyleri

TEKNOFEST Saglikta Yapay Zeka Yarismasi - Konsolide Bulgu Raporu
(NB15, NB16, NB17, NB19, NB20, NB21-24, NB31, NB32)

Genetik Varyant Patojenite Tahmini Projesi

Rapor tarihi: 2026-07-13

Kapsam: MASTER -> panel pretrain/finetune, COMBINED havuz transferi,
frozen-body finetune, NN/DNN finetune implementasyon karsilastirmasi

1. Bu Rapor Neye Cevap Veriyor

Danisman sorusu: 'Genis bir havuzda (orn. MASTER, ya da MASTER+diger panellerin tumu) bir modeli (ozellikle NN/DNN) on-egitip (pretrain), sonra hedef panelin kucuk bir kisimiyla ince ayar (finetune) yapmayi denediniz mi?' Bu sorunun cevabi: EVET, bu senaryo projede en az uc panelde (KANSER, CFTR, PAH) ve toplam 5 farkli notebook'ta (NB15, NB16, NB17/19/20, NB31, NB32) sistematik olarak denendi. Bu rapor, o denemelerin tamamini; kullanimi egitim verisini, model mimarisini, hiperparametreleri, elde edilen precision/recall/F1/MCC degerlerini ve varilan sonuclari tek bir belgede toplar.

Ozet Sonuc (detaylar sonraki bolumlerde)

- KANSER: MASTER/COMBINED pretrain -> KANSER finetune (NN/DNN) uc ayri notebook'ta (NB16, NB31, NB32) denendi. NB16'da dnn_ft=0.7046 ile o ana kadarki en iyi KANSER sonucuydu; ancak NB31'de ayni fikir farkli implementasyonla tekrarlandiginda nn_ft=0.5577'ye cakildi. NB32'de implementasyon hatalari duzeltildi (frozen-layer kaldirildi, tutarli scaler, F1-tabanlı early stopping) ama sonuc yine de agac modellerin (CatBoost=0.730) gerisinde kaldi (dnn_ft=0.6468).
- CFTR: MASTER pretrain -> frozen body + CFTR'de sadece son katman finetune (S4_FrozenFinetune, NB17/NB20) denendi. Sonuc acik bicimde basarisiz: MCC=0.294, en kotu strateji. Ayni deneyde post-hoc prior-shift duzeltmesi (yeniden egitim GEREKMEDEN) MCC=0.655 ile en iyi sonucu verdi.
- PAH: Klasik pretrain+finetune (agirlik donduerme + kucuk veriyle ince ayar) hic denenmedi. Bunun yerine PAH haric tum panellerle (COMBINED) TAM egitim + BalancedBagging denendi (NB21/22/23) ve bu, tek asamali bir 'pool ve egit' yaklasimidir - finetune degildir.

GENEL YARGI

Uc bagimsiz denemede (KANSER x2 farkli implementasyon, CFTR x1) NN/DNN icin 'dondurulmus/kismi finetune' yaklasimi tutarli bicimde basarisiz oldu ya da agac modellerin (LightGBM/XGBoost/CatBoost/BalancedBagging) gerisinde kaldi. Basarisizligin kok nedeni ayni: hedef panellerin ornek sayisi (CFTR n=111, KANSER n=388, PAH n=372) bir NN'in son katmanini/tamamini guvenilir bicimde yeniden ayarlamak icin yetersiz. Buna karsilik, TEK ASAMALI havuzlama (COMBINED uzerinde tam egitim, finetune yok) ve ozellikle BalancedBagging + post-hoc prior-shift duzeltmesi her ucpanelde de daha guvenilir ve daha yuksek skor uretti.

2. Terminoloji ve Degerlendirme Protokolu (Rapor Boyunca Kullanilan)

2.1 Pretrain / Finetune Nedir (bu projede)

- Pretrain: Genis bir havuzda (MASTER tek basina, ya da MASTER+KANSER+CFTR gibi COMBINED birlesimi) bir NN/DNN'in tum agirliklarinin ilk kez egitilmesi.
- Finetune (tam): Pretrain edilmiş agirliklarla baslayip, hedef panelin (örn. KANSER'in %50'si) train verisiyle TUM katmanlariin dusuk ogrenme orani ($lr=1e-4$) ile nazikce guncellenmesi.
- Finetune (frozen/kismi): Pretrain edilmiş govde (body) dondurulur, sadece son (genelde tek) katman hedef panel verisiyle egitilir. Kapasitesi dusuktur ama az veriyle asiri ogrenmeyi (overfit) onlemesi beklenir.

2.2 Degerlendirme Metrikleri

- LOO-CV MCC: Leave-One-Out capraz dogrulama ile Matthews Correlation Coefficient. Kucuk panellerde (CFTR $n=111$) bootstrap guven araligi anlamsizlasınca ($CI=[0.00-1.00]$) devreye alindi.
- Boot-F1 (%80/20 bootstrap): Final yarisma test dagilimini ($\sim\%80$ benign / $\%20$ patojenik) taklit eden, $N=50$ tekrarlı, benign sabit + patojenik altornekleme (downsample) ile hesaplanan pathogenic-F1. Yarismanin BIRINCIL degerlendirme olcusudur.
- Train-F1 / Overfit Gap: Egitim verisi uzerindeki F1 ile test F1 arasindaki fark; buyuk fark asiri ogrenmeye isaret eder.

Not: Bu rapordaki tum Boot-F1 degerleri, projenin standart 'final-realistic' degerlendirme protokolune (CLAUDE.md) gore hesaplanmistir; train dagilimindaki ($\sim\%50/50$ ya da panel-ici dogal oran) F1 degerleriyle KARISTIRILMAMALIDIR.

3. KANSER Paneli - Pretrain/Finetune Denemeleri (3 Notebook)

KANSER paneli (n=388, patho=268/benign=120), pretrain+finetune fikrinin en fazla test edildiği paneldir. Aynı temel fikir üç farklı notebook'ta (NB16, NB31, NB32), her seferinde bir önceki implementasyon hatası düzeltilerek tekrarlandı.

3.1 NB16 v2 - İlk Başarılı Deneme (dnn_ft=0.7046)

Eğitim verisi: NB15 S1 kurgusu - panelin %50'si (patho+benign stratified) + dengelenmiş MASTER çekirdeği (625 patojenik / 625 benign, SEED=42 ile bir kez örnekledi). Pretrain BU BİRLİK havuzda (MASTER_CORE + panel_train) yapıldı, finetune aynı panelin train kısmı üzerinde sürdü.

Model / Hiperparametreler

- Mimari: SmallMLP (küçük, düzenlenmiş mimari) - BatchNorm YOK (varyans kayması riskine karşı), yüksek dropout + weight_decay.
- Kayıp fonksiyonu: Focal Loss (gamma=2) + sınıf ağırlıklandırma.
- Early stopping: Validasyon F1'ine göre (doğrudan hedef metrik).
- Finetune öğrenme oranı: lr=1e-4, HİCBİR katman dondurulmadı (tüm ağırlıklar nazikçe güncellendi).
- Scaler: Pretrain ve finetune için TUTARLI/birleşik bir scaler (MASTER_CORE + panel_train birleşiminde fit edildi) - finetune aşamasında yeniden fit edilmedi.
- Capraz doğrulama: 5-fold StratifiedKFold (v1'de 3-fold idi, v2'de 5'e çıkarıldı).

Sonuç

Model	Boot-F1 (%80/20)	Not
dnn_ft (finetune DNN)	0.7046	KANSER için o ana kadarki EN İYİ tekil model
stack_lr (6 base + LR meta, finetune dahil)	0.716	dnn_ft'i base olarak içeren stacking, projede o ana kadarki EN İYİ KANSER sonucu

6 base model seti: *lightgbm*, *catboost*, *nn (scratch)*, *dnn (scratch)*, *nn_ft (finetune)*, *dnn_ft (finetune)*. Meta-learner: *Logistic Regression (class_weight=balanced)* - *GBM meta-learner overfit ettiği için (train F1 0.84-0.87) tercih edilmedi.*

3.2 NB31 - Aynı Fikir Farklı Implementasyonla Başarısız Oldu (nn_ft=0.5577)

NB31'de KANSER için COMBINED havuz (MASTER+KANSER+CFTR = 3414 satır) üzerinde pretrain yapıp KANSER train (n=385, %50/50 split) üzerinde finetune tekrarlandı. Ancak sonuç carpıcı biçimde kötüleşti: 21 denemenin EN KOTUSU oldu.

Deney	Boot-F1	Std	AUPRC	Precision	Recall	FP	FN
E6_alpha_0.5 (en iyi, stacking blend)	0.7201	0.042	0.969	0.931	0.917	9	11
E1_nn_ft (finetune NN)	0.5577	0.034	0.895	0.860	0.925	20	10

Kok Neden Analizi: NB16 vs NB31 Implementasyon Farklari

Boyut	NB16 (basarili, dnn_ft=0.7046)	NB31 (basarisiz, nn_ft=0.5577)
Katman dondurma	Hic dondurmuyor, tum katmanlar lr=1e-4 ile guncelleniyor	params[:2] freeze - SADECE son lineer katman egitiliyor (cok agresif)
Scaler	Birlesik basis (MASTER_CORE + panel_train) uzerinde TEK scaler	Pretrain'de kendi scaler'i, finetune'da HER FOLD'da yeni scaler -> dagilim kaymasi
Early stopping	Validasyon F1 uzerinden (dogrudan hedef metrik)	Validasyon loss uzerinden (F1 ile korelasyonu dolayli)
Pretrain verisi	MASTER_CORE (625/625 dengeli)	COMBINED (3414, dengesiz)

BULGU

Gorunuste kucuk implementasyon detaylari (hangi katmanlari donduruldugu, scaler tutarligi, early-stopping kriteri) 0.15 puanlik (0.7046 -> 0.5577) fark yaratti. Bu, 'ayni fikri' tekrar test ederken degerlendirme protokolunun BIREBIR ayni olmasi gerektiginin somut kanitidir.

3.3 NB32 - Implementasyon Duzeltildi, Ama Agac Modelleri Yine de Gecemedi

NB32'de NB31'in 4 implementasyon hatasi (yukaridaki tablo) duzeltildi: (1) katman dondurmeye kildirildi - tum katmanlar lr=1e-4 ile guncelleniyor, (2) fold-basi yeniden fit edilen scaler yerine birlesik/tutarli scaler, (3) loss-tabanlı early stopping yerine F1-tabanlı, (4) weight_decay 1e-4 -> 1e-3 + pos_weight eklendi.

Deney	Boot-F1	Std	AUPRC	FP	FN
E0_P1_BALANCED_625_dnn_ft	0.6468	0.077	0.934	7	41
E0_P1_BALANCED_625_nn_ft	0.6018	0.055	0.947	12	30
E0_P3_COMBINED_RAW_dnn_ft	0.6213	0.045	0.927	13	22
E0_P3_COMBINED_RAW_nn_ft	0.6176	0.049	0.904	13	22

Karsilastirma icin ayni notebook'ta 7 model x 10 farkli egitim havuzu (pool) sistematik olarak tarandi. Sonuc: duzeltilmis finetune (dnn_ft=0.6468) NB31'in 0.5577'sinden yukari cikti, ama agac modellerinin seviyesine (CatBoost ortalama 0.663, en iyi tekil P9_REVERSE_6040_catboost_with_fe=0.7300) hicbir zaman ulasamadi.

Model Ailesi Siralamasi (10 pool ortalaması, NB32)

Siralama	Model	Ort. Boot-F1	Ort. Overfit Gap
1	CatBoost	0.663	0.081
2	XGBoost	0.642	0.101
3	LightGBM	0.641	0.095
4	NN finetune (nn_ft)	0.607	0.245

5	DNN scratch	0.588	0.127
6	DNN finetune (dnn_ft)	0.577	0.263
7	NN scratch	0.571	0.152

KANSER GENEL SONUC (3 notebook, 2026-06-22/23)

Finetune duzeltmeleri yeterli olmadı: KANSER (n=388) NN finetune için örnek sayısı çok küçük. CatBoost + P9_REVERSE_6040 (egitim havuzunu final test dagilimina yaklastiran %60 benign / %40 patojenik gercek yeniden-orneklem) + hafif feature engineering kombinasyonu (Boot-F1=0.7300) NN/DNN finetune'un ULASAMADIGI bir seviyeye agac modelleriyle ulasti. KANSER için GUNCEL EN IYI SONUC budur (P9_REVERSE_6040_catboost_with_fe, NB32).

4. CFTR Paneli - Frozen-Body Finetune Denemesi (NB17 / NB19 / NB20)

CFTR en küçük panel (n=111, benign=SADECE 21). Bu, hem finetune'un basarisiz oldugu hem de neden basarisiz oldugunun en net gorulebildigi panel oldu.

4.1 S4_FrozenFinetune Stratejisi (NB17)

Kurulum

- Pretrain verisi: MASTER (2931 satir, tam veri).
- Finetune yaklasimi: FROZEN body - MASTER'da egitilen agin govdesi dondurulur, SADECE CFTR verisiyle son katman egitilir.
- Finetune verisi: CFTR'nin kendisi (n=111, 21 benign - COK KUCUK).
- Degerlendirme: LOO-CV (Leave-One-Out, 111 ornegin tamamı, 21 benign'in tamamı degerlendirmede) + MCC (Chicco & Jurman 2020).

7 Strateji Karsilastirmasi (LOO-CV MCC - birincil metrik)

Strateji	LOO-MCC	LOO-F1	LOO-AUC	Boot-mean	Boot-std	Train-F1	Overfit
S0_MASTER-only	0.627	0.898	0.942	0.728	0.107	0.979	ORTA
S1_MASTER-core	0.608	0.877	0.912	0.783	0.099	0.985	ORTA
S2_SMOTE-CFTR	0.561	0.924	0.838	0.493	0.051	1.000	OK
S3_TabPFN	atlandi	-	-	-	-	-	N/A
S4_FrozenFinetune	0.294	0.500	0.857	0.370	0.258	0.500	OK
S5_BalancedBagging	0.572	0.855	0.937	0.754	0.128	0.935	OK
S6_PriorShift	0.655	0.919	0.942	0.692	0.088	0.978	OK

S4_FrozenFinetune SONUCU: ACIK BASARISIZLIK (MCC=0.294)

S4, 7 stratejinin en kotosudur - S6_PriorShift'in (0.655) NEREDEYSE YARISI kadar MCC. Train-F1 dahi 0.500'e dusuyor (diger stratejilerde 0.93-1.00 araliginda). Yorum (NB17): 'Frozen body + CFTR finetune, MASTER pretrain bilgisini CFTR'ye aktaramadi. n=111 cok kucuk, son katman yeterli kapasitede degil.' Yani sadece son katmani egitmek (govdeyi dondurup) hem MASTER'daki bilgiyi CFTR'ye tasimada yetersiz kaldı hem de kendi basına CFTR'nin kucuk ornek sayisiyla ogrenemedi.

Aynı deneyde kazanan strateji S6_PriorShift oldu: MASTER-only modelin (S0, LightGBM, HICBIR yeniden egitim/finetune olmadan) cikti olasiliklarına post-hoc bir prior-shift duzeltmesi (Saerens 2002: egitim onseli $p_{i_train}=0.73$ -> test onseli $p_{i_test}=0.20$) uygulanarak MCC 0.627 -> 0.655'e cikti. Confusion matrix (S6, LOO-CV): 18/21 benign dogru (specificity=%86), 79/90 patojenik dogru.

4.2 COMBINED Havuz Transferi (NB19/NB20) - Finetune Degil, Ama Ilgili Karsilastirma

NB19'da klasik finetune yerine, egitim havuzunu MASTER'dan COMBINED'a (MASTER+KANSER+PAH

= 3691 satir) genisletip HICBIR finetune yapmadan CFTR'ye transfer test edildi.

Strateji	n_egitim	LOO-MCC	Boot-mean	Boot-std	TN	FP	FN	TP
S0_MASTER-only	2931	0.6552	0.6915	0.0877	18	3	11	79
S0c_COMBINED	3691	0.6436	0.8629	0.1327	21	0	19	71

NB20'de bu COMBINED yaklasimi (LGBM + prior-shift, S0c_COMBINED) CFTR icin KESINLESEN final model oldu: LOO-MCC=0.644, Boot-F1=0.863, Precision=1.0 (FP=0). NB34'te ayrica feature engineering eklenmesi denendi ama LOO-MCC'yi gecemedi (-0.036), bu yuzden FE eklenmedi.

5. PAH Paneli - Klasik Finetune Denenmedi, COMBINED Havuz Transferi Test Edildi

PAH (n=372, patho=310/benign=62) için literalde 'NN pretrain -> PAH'in küçük bir kısmıyla finetune' senaryosu HIC çalıştırılmadı. Bunun yerine 'PAH hariç tüm verilerle (COMBINED) eğit, doğrudan PAH'a transfer et' yaklaşımı (tek aşamalı, finetune YOK) NB21, NB22 ve NB23'te sistematik olarak test edildi. Bu bölüm, danışmanın sorduğu PAH örneğine en yakın çalışılmış deney seti olduğu için dahil edilmistir; ancak ONEMLİ FARK: burada bir NN'in ağırlıkları ONCE COMBINED'da sonra PAH'ta ayarlanmıyor - tek bir model (cogunlukla LightGBM/BalancedBagging) COMBINED'in TAMAMINDA bir kez eğitilip değişmeden PAH'a uygulanıyor.

5.1 NB21 - 7 Strateji Karsilastirmasi (COMBINED = MASTER+KANSER+CFTR, PAH hariç)

Strateji	n_egitim	MCC(raw)	MCC(prior)	Boot-F1	Std	Prec	Recall	FP	FN
P4_COMBINED_BalBag	3430	0.529	0.516	0.582	0.045	0.942	0.853	16	45
P2_BalancedBagging	2931	0.519	0.512	0.582	0.044	0.942	0.850	16	46
P0c_COMBINED	3430	0.497	0.439	0.590	0.054	0.947	0.762	13	73
P0_MASTER-only	2931	0.463	0.399	0.555	0.054	0.945	0.723	13	85

Tam 7 strateji tablosu NB21 raporunda mevcuttur (P0, P0c, P1, P1c, P2, P3, P4); yukarıda özet/en iyi 4 satır gösterilmiştir.

5.2 NB23 - Havuz Katkı Analizi (Hangi Panel Ne Kadar Katkıda Bulunuyor)

Katkı	MCC Delta	Yorum
KANSER (+120 benign)	+0.002	Neredeyse yok - KANSER benign'leri PAH'a az bilgi veriyor
CFTR (+21 benign)	+0.015	Sasirtici! 21 benign 120'den daha değerli
COMBINED (+141 benign, ikisi birden)	+0.034	Sinerjik - toplam parçaların toplamından büyük

5.3 NB24 - Plato Kirma Girişimi (TabPFN + Label-Shift) - BASARISIZ

NB24'te PAH'taki MCC=0.53/Boot=0.58 platosunu kırmak için TabPFN (in-context öğrenme, özel bir pretrain biçimi) ve label-shift düzeltmeleri (BBSE, Saerens EM, spline kalibrasyon) denendi. En iyi sonuç D3 SplineCal+PriorShift: MCC=0.503, Boot=0.581 - NB21 P4'u (0.582) GECEMEDİ. Sonuç: 'Chatterji tavanı' doğrulandı, yani PAH'ta mevcut özelliklerle ulaşılabilecek tavana zaten yaklaşılmış durumda.

PAH GENEL SONUC

PAH'ta klasik NN pretrain->finetune hic denenmedi (bosluk budur). Ancak denenen COMBINED tek-asamali transfer + BalancedBagging yaklasimi (NB21 P4, Boot-F1=0.582, MCC=0.529) kesinlesen final modeldir. TabPFN dahil ileri denemeler (NB24) bu platoyu asamadi. PAH icin danisma EDA'sinin da (train dagiliminda best=0.925 = floor 0.905) bagimsiz olarak dogruladigi gibi, bu panelde ek modelleme cabasi getirisi dusuk.

6. Uc Panel Bir Arada: Neden Ayni Sonuca Vardik

Panel	Finetune Turu	En Iyi Finetune Sonucu	En Iyi Alternatif (Agac/BalBag)	Kazanan
KANSER	Tam finetune (NB16) / Duzeltilmis tam finetune (NB32)	dnn_ft=0.7046 (NB16, stacking icinde 0.716)	CatBoost+P9_REVERSE_60 40+FE=0.7300 (NB32)	Agac modeli (NB32)
CFTR	Frozen-body finetune (NB17 S4)	MCC=0.294 (basarisiz)	S0c_COMBINED+prior-shift =0.863 Boot-F1 / MCC=0.655 (NB20)	Prior-shift + havuzlama
PAH	Hic denenmedi (sadece tek-asamali COMBINED transfer)	N/A	P4_COMBINED_BalBag=0.5 82 Boot-F1 (NB21)	BalancedBagging

6.1 Ortak Kok Neden

- Ornek buyuklugu darbogazi: Hedef panellerin boyutu (CFTR=111, KANSER=388, PAH=372) bir NN'in agirliklarini (ozellikle governeyi tam yeniden ayarlamak icin) guvenilir bicimde ince ayar yapmaya yetmiyor. Frozen-body yaklasiminda (CFTR) kapasite yetersiz kaliyor; tam finetune'da (KANSER) ise varyans/overfit riski artiyor (NB32: nn_ft overfit gap=0.245, dnn_ft=0.263 - agac modellerinin 0.08-0.10 gap'inin 2.5-3 kati).
- Ters dagilim sorunu finetune'la cozulmuyor: Projenin en kritik bulgusu olan 'final test %80 benign / egitim verisi %70+ patojenik' ters dagilimi, finetune ile degil, egitim HAVUZUNUN kompozisyonu (P9_REVERSE_6040 gibi %60 benign / %40 patojenik gercek yeniden-orneklem) cozuluyor. Bu, finetune'un cozmeye calistigi sorunla ORTOGONAL bir eksen.
- BalancedBagging'in teorik ustunlugu: Chatterji et al. (2022, NeurIPS) BalancedBagging'in worst-case label-shift altinda minimax-optimal oldugunu gostermistir. Ucu panelde de (CFTR NB17/20, PAH NB21, KANSER dolayli olarak NB32'nin reverse-pool bulgusu) bu teorik ongoru pratikte dogrulandi.

7. Sonuc: Bu Deneyi Tekrar Yapmalı Miyiz?

Danismanin sordugu senaryo ('genis havuzda pretrain, hedef panelin kucuk kisminde finetune') KANSER'de 2 farkli implementasyonla (NB16 basarili gorunumlu ama NB31'de tekrarlanamadi, NB32'de duzeltilip agac modellerinin altinda kaldi) ve CFTR'de 1 kez (NB17 S4, acik basarisizlik) toplam UC KEZ test edildi. PAH'ta ise hic test edilmedi - bu, projenin tespit ettigi tek gercek bosluktur.

İki somut, henuz denenmemis varyant (eger tekrar denenecekse)

- (1) PAH icin NN pretrain (COMBINED, PAH haric) -> PAH finetune, NB16'nin BASARILI protokolune (hicbir katman dondurmadan, dusuk lr=1e-4, tutarli/birlesik scaler, F1-tabanlı early stopping) SADIK kalarak.
- (2) Agac modelleri icin 'devam egitimi' (orn. LightGBM'de init_model ile), yani NN olmayan bir pretrain->finetune analogu - bu hic denenmedi ve BalancedBagging'in uzerine ek bir kaldirac olabilir.

Bu iki varyant disinda, mevcut kanit (3 bagimsiz basarisiz/zayif finetune denemesi) ayni yaklasimin oldugu gibi tekrarini ONERMEMEKTEDIR. Mevcut en iyi modeller (KANSER->P9_REVERSE_6040_catboost_with_fe 0.730, CFTR->S0c_COMBINED+prior-shift 0.863, PAH->P4_COMBINED_BalBag 0.582) hicbiri finetune icermez.

Ek: Kaynak Notebook ve Rapor Dosyaları

Notebook	Konu	Kaynak PDF / CSV
NB15 v2	Panel-bazli S1-S4 senaryolari, ilk finetune denemesi (S3/S4)	reports/NB15_panel_specific_report.pdf
NB16 v2	FE ablasyonu + 6 base (nn_ft, dnn_ft dahil) + stacking	reports/NB16_fe_stacking_report.pdf
NB17	CFTR 7 strateji (S4_FrozenFinetune dahil) + prior-shift	reports/NB17_cftr_refinement_report.pdf
NB19	CFTR: MASTER-only vs COMBINED havuz karsilastirmasi	results/v9_cftr_combined/cftr_combined_results.csv
NB20	CFTR ensemble + threshold refinement (final model)	reports/NB20_cftr_ensemble_report.pdf
NB21	PAH 7 strateji (COMBINED + BalancedBagging)	reports/NB21_pah_refinement_report.pdf
NB22	PAH ensemble + kalibrasyon	reports/NB22_pah_ensemble_report.pdf
NB23	PAH COMBINED havuz katkı analizi	reports/NB23_pah_combined_report.pdf
NB24	PAH plato-kirma (TabPFN + label-shift)	reports/NB24_pah_tabpfn_report.pdf
NB31	KANSER kumulatif entegrasyon (finetune tekrari, basarisiz)	reports/NB31_kanser_cumulative_report.pdf
NB32	KANSER pool sweep + finetune duzeltmesi	reports/NB32_pretrain_distribution_report.pdf